
Journal de Bord

NextCredit

Plateforme Intelligente d'Évaluation du Risque Crédit

Étudiante : Sarra Jouini

Filière : cycle d'Ingénieur / business intelligence

Période : 01 Janvier 2026 — 14 Juin 2026

Introduction

Le présent journal de bord retrace, semaine après semaine, l'intégralité du parcours réalisé dans le cadre du Projet de Fin d'Études (PFE) intitulé **NextCredit**. Ce projet ambitionne de répondre à une problématique concrète du secteur financier : comment moderniser l'évaluation du risque crédit en remplaçant les processus manuels et les modèles statistiques classiques par une plateforme intégrée, intelligente et explicable , **NextCredit** est une solution end-to-end qui combine un pipeline de données automatisé (Talend + SQL Server), des modèles d'apprentissage automatique et profond, une API REST déployée via Flask, un tableau de bord décisionnel interactif (Power BI) et une interface utilisateur moderne développée avec Angular. Ce journal documente fidèlement les missions accomplies, les apprentissages réalisés, les compétences mobilisées, les difficultés rencontrées et les solutions apportées pour chacune des dix phases du projet,

SEMAINES 1-2 | T1 — Cahier de Spécifications

📅 01 Janvier – 11 Janvier 2026

🔄 Missions accomplies

- Réalisation d'une recherche bibliographique approfondie sur le risque crédit, les méthodes de scoring bancaire.
- Rédaction du cahier des charges complet : besoins fonctionnels (scoring automatique, explicabilité, tableau de bord, gestion des rôles) et non-fonctionnels (performance, sécurité, scalabilité).
- Définition de l'architecture globale de la plateforme NextCredit en 4 couches : ETL → Data Warehouse → Couche ML/API → Interface utilisateur.
- Choix et validation du nom du projet « NextCredit » et de son positionnement comme plateforme end-to-end.

📖 Apprentissages clés

- Processus d'octroi de crédit dans les institutions financières : de la demande à la décision.
- Méthodes de scoring bancaire traditionnelles vs approches ML modernes.
- Réglementation Basel III : exigences en fonds propres, probabilité de défaut (PD), perte en cas de défaut (LGD), exposition au défaut (EAD).
- Modélisation UML appliquée à un projet data : cas d'utilisation, classes, séquences.
- Planification de projet avec diagramme de Gantt.

🔧 Compétences mobilisées

- Hard skills : Recherche académique, rédaction technique, modélisation UML (StarUml), planification (JIRA).
- Soft skills : Rigueur analytique, communication avec l'encadrant, structuration de la pensée, gestion du temps.
- Outils : Microsoft Word, staruml, jira .

⚠️ Difficultés rencontrées & Solutions

⚠️ **Difficulté** : Définir le périmètre exact du projet était complexe : risque de sur-périmétrage (trop de fonctionnalités) ou sous-périmétrage (solution trop limitée).

✅ **Solution** : Organisation de séances de cadrage hebdomadaires avec l'encadrant pour prioriser les fonctionnalités .

📅 Organisation & Planning

La semaine 1 a été consacrée à la recherche bibliographique et à la prise en main des outils de modélisation. La semaine 2 a été dédiée à la rédaction du cahier de spécifications et à la construction du Gantt. Des points quotidiens de 30 minutes ont été maintenus pour suivre l'avancement. Un dépôt GitHub a été initialisé dès le début pour versionner tous les documents du projet.

Défis pour la prochaine période

- Démarrer l'analyse exploratoire des données (EDA) sur le dataset Home Credit Default Risk.
- Mettre en place l'environnement Python (Anaconda, Jupyter Notebook, bibliothèques Pandas/Matplotlib/Seaborn).
- Produire un premier rapport EDA avec statistiques descriptives et visualisations clés.

SEMAINES 3–4 | T2 — Analyse Exploratoire des Données (EDA)

 12 Janvier – 25 Janvier 2026

Missions accomplies

- Chargement et inspection du dataset Home Credit Default Risk : 307 511 lignes, 122 variables.
- Analyse des valeurs manquantes : identification de 67 colonnes avec plus de 40% de valeurs manquantes, cartographie complète des taux de complétion.
- Analyse univariée : distributions des variables numériques (histogrammes, boxplots) et catégorielles (barplots), détection des outliers.
- Analyse bivariable : corrélations avec la variable cible (TARGET), heatmap de corrélation entre variables numériques.
- Profilage des clients à risque : identification des variables les plus discriminantes (EXT_SOURCE_1/2/3, DAYS_BIRTH, AMT_CREDIT).
- Rédaction d'un rapport EDA structuré .

Apprentissages clés

- Visualisation avec Matplotlib et Seaborn : histplot, boxplot, heatmap, pairplot, countplot.
- Concept de déséquilibre des classes (class imbalance) et ses conséquences sur les métriques ML.
- Techniques d'analyse de corrélation : Pearson, Spearman, point-biserial pour variables mixtes.
- Stratégies d'imputation des valeurs manquantes : moyenne (variables numériques), mode (catégorielles).
- Interprétation métier des variables : DAYS_BIRTH (âge client), EXT_SOURCE (scores externes), AMT_ANNUITY (annuité)... .

Compétences mobilisées

- Hard skills : Python (Pandas, NumPy, Matplotlib, Seaborn), Jupyter Notebook, analyse statistique descriptive et inférentielle.
- Soft skills : Curiosité analytique, rigueur dans l'interprétation des résultats, documentation claire des observations.
- Outils : Jupyter Notebook, VS Code, Git/GitHub pour versionner les notebooks.

Difficultés rencontrées & Solutions

Difficulté : Dataset de 307 511 lignes avec 67% de valeurs manquantes sur certaines colonnes — risque de biais d'imputation et de perte d'information significative.

Solution : Stratégie d'imputation différenciée : moyenne pour les variables numériques à distribution normale, médiane pour les distributions asymétriques, mode pour les catégorielles. Les colonnes avec >80% de manquants ont été marquées pour suppression conditionnelle lors du feature engineering.

Organisation & Planning

Semaine 3 : mise en place de l'environnement Anaconda, exploration initiale du dataset, analyse des valeurs manquantes et distributions univariées. Semaine 4 : analyses bivariées, corrélations, rédaction du rapport EDA.

Défis pour la prochaine période

- Installer et configurer SQL Server Express et SSMS pour la mise en place de la Staging Area.
- Concevoir le schéma de la base de staging (tables, types, contraintes) à partir des colonnes du dataset.
- Démarrer en parallèle la modélisation du Data Warehouse en schéma constellation.

SEMAINES 5–6 | T3 & T4 — Staging Area + Conception Data Warehouse

 26 Janvier – 08 Février 2026

Missions accomplies

- Installation et configuration de SQL Server Express 2022 et SQL Server Management Studio (SSMS) sur l'environnement de développement.
- Création de la base de données de Staging (STG_NEXTCREDIT) avec 8 tables miroir du dataset source.
- Définition des contraintes d'intégrité : clés primaires, types de données adaptés (NVARCHAR, DECIMAL, DATE), index sur les colonnes de jointure.
- Modélisation du Data Warehouse en schéma constellation

Apprentissages clés

- Modélisation dimensionnelle : différences entre schéma étoile (star schema), schéma flocon et schéma constellation, avantages et inconvénients de chaque approche.
- Concepts de Data Warehouse : tables de faits vs dimensions.
- Administration SQL Server
- Staging Area : rôle tampon entre les sources et le DWH, importance pour la qualité des données.

Compétences mobilisées

- Hard skills : SQL, modélisation de bases de données, SSMS, conception DWH.
- Soft skills : Rigueur dans la documentation, capacité à prendre des décisions d'architecture justifiées.
- Outils : SQL Server Express 2022, STARUML.

Difficultés rencontrées & Solutions

 **Difficulté :** Choix entre schéma étoile et schéma constellation pour le Data Warehouse

 **Solution :** Adoption du schéma constellation après benchmarking.

Organisation & Planning

T3 et T4 ont été menées en parallèle sur les semaines 5 et 6. Semaine 5 (matin) : installation SQL Server + création de la Staging Area. Semaine 5 (après-midi) : début de la modélisation dimensionnelle du DWH. Semaine 6 : finalisation du DDL DWH.

Défis pour la prochaine période

- Installer Talend Open Studio et configurer le connecteur JTDS pour SQL Server.
- Développer les jobs ETL d'extraction des fichiers CSV vers la Staging Area.
- Implémenter les transformations de données (nettoyage, encodage, normalisation) dans Talend.
- Tester le chargement complet du dataset (307 511 lignes) dans le DWH.

SEMAINES 7–9 | T5 — ETL Talend

 09 Février – 01 Mars 2026

Missions accomplies

- Installation de Talend Open Studio for Data Integration 8.0 et configuration de l'environnement Java (JDK 11).
- Configuration du connecteur JTDS pour SQL Server Express : paramétrage du driver, test de connectivité, résolution du problème d'authentification Mixed Mode.
- Développement de jobs dédiés pour chaque table du Data Warehouse .
- Développement du Job Maître d'Orchestration (tRunJob) : automatisation séquentielle de l'ensemble des jobs.
- Mise en place de la gestion des erreurs ETL : logs d'erreurs dans une table STG_ERROR_LOG, alertes par email.
- Test de performance : chargement complet de 307 511 lignes en 8 minutes 42 secondes.
- Planification automatique via le Job Maître pour une exécution quotidienne..

Apprentissages clés

- Architecture ETL (Extract-Transform-Load) : principes, bonnes pratiques, différence avec ELT.
- Talend Open Studio : interface graphique, composants principaux (tFileInputDelimited, tDBInput, tDBOutput, tMap, tFilterRow, tAggregateRow).
- Composant tMap : jointures complexes, expressions Java dans les transformations, gestion des rejets.
- Driver JTDS : alternative open-source au driver Microsoft JDBC pour SQL Server, configuration URL de connexion.
- Gestion des erreurs ETL : stratégies de reprise sur erreur, logging, monitoring des jobs.
- Optimisation ETL : batch size, parallélisme des sous-jobs, compression des données en transit.

Compétences mobilisées

- Hard skills : Talend Open Studio, ETL design, SQL Server, Java (expressions dans tMap), gestion de pipelines de données.

- Soft skills : Débogage méthodique, patience face aux erreurs de configuration, documentation des jobs.
- Outils : Talend Open Studio 8.0, SSMS, SQL Server Profiler (monitoring des requêtes), Git.

Difficultés rencontrées & Solutions

 **Difficulté** : Problème d'authentification JTDS avec SQL Server Express : connexion refusée avec l'erreur 'Login failed for user NT AUTHORITY\ANONYMOUS LOGON'.

 **Solution** : Activation du mode Mixed Authentication dans SQL Server Configuration Manager, création d'un utilisateur SQL dédié (talend_user) avec les permissions nécessaires, et mise à jour de la chaîne de connexion JTDS avec domain=localhost.

Organisation & Planning

Semaine 7 : installation Talend, configuration JTDS, développement Job ETL 1 (Extraction). Semaine 8 : développement Job ETL 2 (Transformation) — phase la plus complexe avec le composant tMap. Semaine 9 : développement des jobs dédiés par table (Job_STG_Load, Job_DIM_CLIENT, Job_DIM_TEMPS, Job_FACT_CREDIT...), puis intégration dans le Job Maître d'orchestration, tests de performance et documentation.

Défis pour la prochaine période

- Installer Power BI Desktop et établir la connexion au Data Warehouse SQL Server.
- Créer les mesures DAX pour les KPIs de risque crédit (taux de défaut, score moyen, montant moyen).
- Concevoir la maquette du tableau de bord décisionnel (wireframe) avant développement.

SEMAINES 10–12 | T6 — Tableau de Bord Décisionnel (Power BI)

 02 Mars – 22 Mars 2026

Missions accomplies

- Connexion Power BI Desktop au Data Warehouse SQL Server via DirectQuery et Import Mode (choix Import pour les performances).
- Modélisation du modèle de données Power BI : relations entre FACT_CREDIT et les 4 tables de dimensions, cardinalités, directions de filtrage.
- Création de mesures DAX essentielles.
- Conception et développement du tableau de bord principal (5 pages).
- Implémentation de visualisations avancées.
- Mise en place de filtres dynamiques (slicers) : période, type de crédit, segment client, niveau de risque.
- Publication du rapport sur Power BI Service et configuration du rafraîchissement automatique des données.

Apprentissages clés

- Power BI Desktop : interface, connecteurs de données, Power Query pour la transformation.

- DAX (Data Analysis Expressions) : fonctions de base (SUM, AVERAGE, COUNT), fonctions d'intelligence temporelle et contexte de filtre.
- Modèle de données Power BI : schéma en constellation dans Power BI, relations actives/inactives, bidirectionnalité.
- Visualisations avancées.
- Power BI Service : espaces de travail, partage de rapports, gestion des accès, passerelle de données.

Compétences mobilisées

- Hard skills : Power BI Desktop, DAX, Power Query (M), modélisation de données, Business Intelligence, visualisation de données.
- Soft skills : Sens du design, empathie utilisateur (UX), capacité à synthétiser des données complexes en insights actionnables.
- Outils : Power BI Desktop, Power BI Service, SQL Server (source de données).

Difficultés rencontrées & Solutions

 **Difficulté** : La mesure DAX du Taux de Défaut retournait des valeurs incorrectes lors du filtrage croisé entre dimensions.

 **Solution** : Utilisation de CALCULATE() avec ALLSELECTED() pour gérer correctement le contexte de filtre et USERELATIONSHIP() pour activer les relations inactives lors de calculs spécifiques.

Organisation & Planning

Semaine 10 : connexion au DWH, modélisation Power BI, création des mesures DAX de base. Semaine 11 : développement des 5 pages du tableau de bord, visualisations avancées, filtres dynamiques. Semaine 12 : optimisation des performances, publication sur Power BI Service, rapport mobile, tests utilisateurs avec l'encadrant et corrections. Un guide utilisateur (PDF, 12 pages) a été rédigé pour documenter l'utilisation du tableau de bord.

Défis pour la prochaine période

- Démarrer la phase de feature engineering pour préparer les données à l'entraînement des modèles ML.
- Mettre en place l'environnement ML.
- Entraîner et comparer les premiers modèles de base.

SEMAINES 13–16 | T7 — Modèles IA

 23 Mars – 19 Avril 2026

Missions accomplies

- Exploration des différentes approches possibles pour modéliser le risque crédit.
- Réflexion sur les grandes familles de modèles envisageables : modèles classiques d'apprentissage automatique et réseaux de neurones.

- Identification des enjeux liés à l'explicabilité des décisions (pourquoi un crédit est accordé ou refusé).
- Début de réflexion sur la problématique du déséquilibre des classes (clients en défaut minoritaires).

Apprentissages clés

- Compréhension des défis spécifiques au scoring crédit : déséquilibre des données, interprétabilité, seuils de décision.
- Découverte des grandes pistes pour rendre un modèle « explicable » aux décideurs métier. Initiation aux notions de probabilité de défaut et de score de risque.

Compétences mobilisées

- Hard skills : Python (Scikit-learn, XGBoost, LightGBM, TensorFlow/Keras, SHAP, LIME, Optuna, imbalanced-learn), Machine Learning, Deep Learning, explicabilité IA.
- Soft skills : Rigueur scientifique, interprétation critique des résultats, capacité à vulgariser les résultats ML pour des non-experts.
- Outils : Jupyter Notebook, VS Code, Git/GitHub, MLflow (tracking des expériences ML).

Difficultés rencontrées & Solutions

 **Difficulté : Difficulté : Les besoins fonctionnels précis ne sont pas encore complètement définis, rendant difficile le choix d'une approche IA concrète..**

 **Solution : Travailler sur les idées générales et reporter les choix techniques à plus tard, une fois les besoins mieux cernés.**

Organisation & Planning

Cette période a été consacrée à des lectures et à une veille sur les approches IA appliquées au scoring crédit. Des réunions de cadrage ont permis d'affiner progressivement les besoins. Les pistes explorées ont été documentées dans le cahier de bord pour préparer les décisions techniques à venir.

Défis pour la prochaine période

- Développer l'API REST Flask avec les endpoints /predict, /explain et /score.

SEMAINES 17–18 | T8 — Déploiement des Modèles (Flask API)

 20 Avril – 03 Mai 2026

Missions accomplies

- Développement de l'API REST Flask avec endpoints principaux.
- Chargement des modèles sérialisés au démarrage de l'API.

Apprentissages clés

- Flask: framework web Python.
- Flask-RESTX : extension Flask pour la documentation Swagger automatique.
- API REST.

Compétences mobilisées

- Hard skills : Flask, API REST, Python, Swagger/OpenAPI.
- Soft skills : Rigueur dans les tests, documentation technique claire, gestion des cas limites (edge cases).
- Outils : VS Code, Git/GitHub.

Défis pour la prochaine période

- Créer le projet Angular et configurer l'environnement de développement (Node.js, Angular CLI).
- Développer les composants Angular pour le formulaire de demande de crédit et l'affichage des résultats.
- Intégrer l'API Flask depuis Angular avec HttpClient .
- Implémenter la gestion des rôles utilisateurs (analyste, manager, admin).

SEMAINES 19–21 | T9 — Interface Front-End (Angular)

 04 Mai – 24 Mai 2026

Missions accomplies

- Création du projet Angular 17 avec Angular CLI, configuration TypeScript strict, intégration Angular Material pour les composants UI.
- Développement de l'architecture modulaire.
- Développement du module d'authentification : formulaire de connexion.
- Implémentation de la gestion des rôles : 2 rôles (visiteur, analyste) avec vues et permissions différenciées.

Apprentissages clés

- Angular, TypeScript, Html,CSS

Compétences mobilisées

- Hard skills : Angular 17, TypeScript, HTML5/CSS3, intégration API REST.
- Soft skills : Sens du design UX/UI, empathie utilisateur.
- Outils : VS Code, Angular CLI, Node.js 20 LTS, npm, Git/GitHub.

Organisation & Planning

Semaine 19-21 : création du projet Angular, architecture modulaire, authentification JWT, routing ,tableau de bord, gestion des rôles, responsive design, tests end-to-end ,des messages d'erreur.

Défis pour la prochaine période

- Démarrer la rédaction du rapport final PFE : état de l'art, architecture, méthodologie, résultats.
- Préparer le diaporama de soutenance avec les résultats clés et démonstration live.
- Finaliser la documentation technique complète du projet.
- Effectuer une relecture complète du rapport avec l'encadrant.

SEMAINES 22–24 | T10 — Rapport Final PFE & Soutenance

 25 Mai – 14 Juin 2026

Missions accomplies

- Rédaction complète du rapport PFE structuré en sprint.
- Préparation du diaporama de soutenance.
- Soumission du rapport final et du code source (GitHub) à la date limite.

Apprentissages clés

- Rédaction académique : structure d'un rapport PFE.
- Présentation des résultats ML : tableaux comparatifs, matrices de confusion....

Compétences mobilisées

- Hard skills : Rédaction académique, LaTeX, présentation synthèse de résultats techniques.
- Soft skills : Communication orale et écrite, gestion du stress, organisation sous contrainte de temps, esprit de synthèse.
- Outils : Microsoft Word, Canva.

Organisation & Planning

Semaine 22-24 : rédaction des chapitres et finalisation du diaporama

Bilan Global du Projet NextCredit

Au terme des 24 semaines de projet, NextCredit constitue une plateforme complète et fonctionnelle d'évaluation intelligente du risque crédit. L'ensemble des 10 phases planifiées ont été menées à bien, avec des résultats techniques probants. Ce projet a permis de développer une expertise transversale couvrant l'ingénierie des données, le Machine Learning, l'explicabilité IA, le développement web et la Business Intelligence.

Tableau récapitulatif des 10 tâches du projet

Tâche	Période	Durée	Statut	Livrables principaux
T1 — Cahier de Spécifications	01–11 Jan 2026	2 sem.	 Terminé	Cahier des charges, Gantt, diagrammes UML, architecture globale
T2 — EDA	12–25 Jan 2026	2 sem.	 Terminé	Rapport EDA, notebooks Jupyter, 25+ visualisations, stratégie d'imputation
T3 — Staging Area	26 Jan–08 Fév	2 sem.	 Terminé	Base STG_NEXTCREDIT
T4 — Data	26 Jan–08 Fév	2 sem.		DWH

Warehouse			Terminé	
T5 — ETL Talend	09 Fév–01 Mar	3 sem.	☒ Terminé	ETL
T6 — Power BI	02–22 Mar 2026	3 sem.	En cours	Dashboard
T7 — Modèles IA	23 Mar–19 Avr	4 sem.	A venir	modèles ML/DL
T8 — Flask API	20 Avr–03 Mai	2 sem.	A venir	API REST
T9 — Angular Front	04–24 Mai 2026	3 sem.	A venir	Application Angular 17, 8 composants, gestion rôles, responsive design
T10 — Rapport Final	25 Mai–14 Juin	3 sem.	A venir	Rapport PFE , diaporama, soutenance